Ingénieurs 2ème année : Parcours Mathématique & Informatique

Compressive Sensing

CM 2 : Le codage parcimonieux

Nisrine FORTIN

1. Motivations

2. Relaxation convexe
   - Méthode du Basis Pursuit
   - Méthode LASSO

3. Poursuite gloutonne
   - Maching Pursuit
   - Orthogonal Maching Pursuit

1. Motivations

Objectifs de ce chapitre

- En tenant compte de l'hypothèse que α est parcimonieux dans le dictionnaire D, le codage parcimonieux consiste à résoudre le problème de minimisation suivant qu'on appellera la minimisation (ℓ_0) :

$$\min_{\alpha} \|\alpha\|_0 \quad \text{sous la contrainte} \quad D\alpha = x \tag{1}$$

- En tenant compte du bruit additif et de la parcimonie, l'équation (1) devient :

$$\min_{\alpha} \|\alpha\|_0 \quad \text{sous la contrainte} \quad \|x - D\alpha\|_2 \leq \epsilon \tag{2}$$

Les algorithmes du codage parcimonieux

- La résolution des équations (1) et (2) nécessite une recherche exhaustive de la solution la plus parcimonieuse $\widetilde{\alpha}$ et est très complexe à mettre en œuvre.

- Plusieurs méthodes ont été proposées dans la littérature pour contourner ce problème. Principalement, elles peuvent être catégorisées en trois groupes :
  1. Relaxation convexe, par exemple la poursuite de base "Basis Pursuit (BP)" et la méthode LASSO.
  2. Poursuite gloutonne, par exemple la poursuite adaptative ou "Matching Pursuit (MP)" et son extension appelée poursuite adaptative orthogonale ou OMP.
  3. Inférence bayésienne, comme le "sparse bayesian learning".

Relaxation convexe

Pour contourner la complexité liée à la pseudo-norme ℓ_0, la relaxation convexe, remplace "relache" la pseudo-norme ℓ_0 par une norme ℓ_j, $j \geq 1$ et utilise des solveurs convexes pour le résoudre :

$$\min_{\widetilde{\alpha}} \|\widetilde{\alpha}\|_j \quad \text{tel que} \quad \mathrm{D}\widetilde{\alpha} = x \tag{1}$$

Relaxation convexe

1- Méthode du Basis Pursuit

- Pour contourner la complexité liée à la norme ℓ_0, la relaxation convexe, Basis Pursuit, remplace la norme ℓ_0 par une norme ℓ_1

$$\min_{\widetilde{\alpha}} \|\widetilde{\alpha}\|_1 \quad \text{tel que} \quad D\widetilde{\alpha} = x \tag{2}$$

- L'approche de la "Poursuite de base" *Basis Pursuit* utilise des techniques de programmation linéaire pour résoudre le problème codage parcimonieux (2).

Relaxation convexe : Basis Pursuit

- Le problème (2) peut être réécrit comme un problème de programmation linéaire : fonction objectif linéaire sous des contraintes linéaires.

- On considère le problème de programmation linéaire suivant :

$$(\mathrm{LP}) \quad \begin{cases} \min\limits_{(\alpha_j^+,\alpha_j^-)} \sum\limits_{j=1}^{N} \left(\alpha_j^+ + \alpha_j^-\right) \\ \text{s.c} \quad \left[\mathrm{D}|-\mathrm{D}\right] \begin{bmatrix} \alpha^+ \\ \alpha^- \end{bmatrix} = x \\ \begin{bmatrix} \alpha^+ \\ \alpha^- \end{bmatrix} \geq 0 \end{cases}$$

Notation :

$$\alpha_j^+ = \max\left(0, \alpha_j\right), \quad \alpha_j^- = \max\left(0, -\alpha_j\right), \quad \alpha_j = \alpha_j^+ - \alpha_j^- \quad \text{et} \quad |\alpha_j| = \alpha_j^+ + \alpha_j^-.$$

Le problème (LP) est très facile à résoudre, mais on se retrouve avec $2 * K$ composantes à déterminer ! ! !

Relaxation convexe : Basis Pursuit

Proposition

Les deux problèmes (BP) et (LP) sont équivalents.

1. Si $\hat{\alpha}$ est une solution du problème (BP) alors $\left(\hat{\alpha}^+, \hat{\alpha}^-\right)$ est une solution du problème (LP).
2. Si $\left(\hat{\alpha}^+, \hat{\alpha}^-\right)$ est une solution du problème (LP) alors $\hat{\alpha}$ est une solution du problème (BP).

Relaxation convexe

2- Méthode LASSO

La méthode du Lasso (*Least Absolute Shrinkage and Selection Operator*) consiste à estimer le vecteur de paramètres de la solution du problème de reconstruction par

1. minimisation du critère quadratique des moindres carrés sous une contrainte sur la somme des valeurs absolues des coefficients

$$\min_{\widetilde{\alpha}} \|x - D\widetilde{\alpha}\|_2 \quad \text{s.c} \quad \|\widetilde{\alpha}\|_1 \leq t \qquad \text{(LASSO)}$$

2. ou de façon équivalente, par minimisation du critère quadratique pénalisé par la norme ℓ_1 des coefficients.

$$\min_{\widetilde{\alpha}} \frac{1}{2}\|x - D\widetilde{\alpha}\|_2^2 + \lambda\|\widetilde{\alpha}\|_1 \qquad \text{(LASSO)}$$

Relaxation convexe : LASSO

- L'introduction d'une pénalisation réduit la variabilité de l'estimation, améliorant ainsi la précision de prédiction.
- La pénalisation de type ℓ_1 rétrécit certains coefficients, alors que les autres sont annulés exactement, aboutissant ainsi à des modèles parcimonieux.
- Le paramètre λ contrôle la régularisation : plus ce paramètre augmente plus les composantes $\widetilde{\alpha}_i$ de $\widetilde{\alpha}$ issues du LASSO tendent vers 0 et pour un λ suffisamment grand, certains sont exactement égaux à zéro.

Dans les statistiques de grande dimension, le LASSO nous permet de définir un modèle linéaire dans le cas où le nombre de variables explicatives est plus grand que le nombre d'observations. Ce cas rend la méthode des moindres carrées ordinaires inexploitable. De plus, le LASSO permet de déterminer un modèle linéaire avec un aspect prédictif très intéressant.

Relaxation convexe : LASSO

- Problème standard des moindres carrés :

$$\min_{\alpha \in \mathbb{R}^K} \left\| x - D\alpha \right\|_2^2 \Longrightarrow \alpha^* = \left(D^T D\right)^{-1} D^T x$$

- Ridge regression :

$$\min_{\alpha \in \mathbb{R}^K} \left\| x - D\alpha \right\|_2^2 + \lambda \|\alpha\|_2 \Longrightarrow \alpha^* = \left(D^T D + \lambda I_K\right)^{-1} D^T x$$

- Le problème LASSO :

$$\min_{\alpha} \frac{1}{2} \left\| x - D\alpha \right\|_2^2 + \lambda \|\alpha\|_1 \qquad \text{(LASSO)}$$

$\|\alpha\|_1 = \sum_{j=1}^{K} |\alpha_j|$ et $|.|$ n'est pas dérivable. Pour y remédier : $\alpha_j = \alpha_j^+ - \alpha_j^-$ et $|\alpha_j| = \alpha_j^+ - \alpha_j^-$.

On peut reformuler le problème du LASSO avec des variables positives :

$$\min_{(\alpha^+, \alpha^-)} \frac{1}{2} \left\| x - D\alpha^+ + D\alpha^- \right\|_2^2 + \lambda e^T \left(\alpha^+ - \alpha^-\right).$$

Poursuite gloutonne

Les méthodes de la poursuite adaptative consistent à

- Trouver itérativement dans le dictionnaire D l'atome le plus corrélé avec le signal,
- Ôter la contribution de cet atome au signal
- Recomencer le processus jusqu'à obtention d'un nombre d'éléments égal à la dimension du signal.

Algorithme général de la poursuite gloutonne

Les méthodes de la poursuite adaptative suivent des algorithmes itératives et généralement faciles à mettre en œuvre.

- À chaque itération, elles sélectionnent un ou plusieurs atome du dictionnaire D en fonction de sa corrélation avec le vecteur x.
- Puis, elles calculent une approximation du signal et mettent à jour le résiduel qui sera utilisé dans la prochaine itération.

- ⇝ Les algorithmes gloutons se distinguent notamment par la méthode de sélection des atomes de D et sur la façon dont le résiduel est mis à jour.
- ⇝ La poursuite adaptative (MP) est la version la plus simple des algorithmes gloutons.

La poursuite adaptative

3.1 Maching Pursuit

Le principe de la méthode Matching Pursuit

Décomposer itérativement le signal $x \in \mathbb{R}^N$ dans le dictionnaire $D \in \mathcal{M}_{N \times K}(\mathbb{R})$ par sélection d'un atome à chaque itération :

$$x = \underbrace{\alpha_1^{(n)} d_1 + \alpha_2^{(n)} d_2 + \ldots + \alpha_K^{(n)} d_K}_{\text{Approximation de x après n itérations}} + \underbrace{R^{(n)}}_{\text{Résiduel après n itérations}} .$$

d_j désigne la $j^{\text{ème}}$ colonne de la matrice D.

Algorithme général du MP

- **Initialisation :**

$$x = \underbrace{0d_1 + 0d_2 + \ldots + 0d_K}_{\text{Initialisation}} + \underbrace{R^{(0)}}_{\text{Résiduel initial}} .$$

- **Première étape :** On cherche à oter du résiduel $R^{(0)}$ l'atome de plus grande contribution.

$$R^{(0)} = z_{m_1} d_{m_1} + R^{(1)}.$$

1. Calculer la distance de $R^{(0)}$ à chaque sous-espace vectoriel engendré par d_j :
   1. On projette le vecteur résiduel $R^{(0)}$ sur $\mathrm{Vect}\,(d_j)$:
   $$\forall j \in [\![1, K]\!], \quad e(j) = \min_{z \in \mathbb{R}} \|R^{(0)} - z d_j\|_2^2.$$
   2. On calcule la contribution (la composante de la projection orthogonale de $R^{(0)}$ sur d_j).
2. On séléctionne l'atome "le plus proche" de $R^{(0)}$:
   1. On cherche la plus petite distance parmi les distances $e(j)$, $j \in [\![1, K]\!]$.
   2. On renvoie la position m_1 de l'atome.
   3. On calcule la contribution de cet atome, z_{m_1}.
3. On obtient $x = \underbrace{z_{m_1} d_{m_1}}_{\text{La première approximation de x}} + R^{(1)}$.
4. *Comment déduire notre solution à l'étape 1 ?* On vient de mettre à jour la composante m_1 donc on met à jour $\alpha_{m_1}^{(1)}$.
$$\alpha_{m_1}^{(1)} = \alpha_{m_1}^{(0)} + z_{m_1}.$$

Algorithme général du MP

- **À l'itération k**, on cherche l'atome d_{m_k} qui contribue le plus au résiduel de l'étape précédente $\mathrm{R}^{(k-1)}$:

$$\mathrm{R}^{(k-1)} = \underbrace{z_{m_k}\mathrm{d}_{m_k}}_{\textbf{Contribution de l'atôme } \mathbf{d}_{m_k}} + \underbrace{\mathrm{R}^{(k)}}_{\textbf{Résiduel après k itérations}} .$$

Mise à jour de la représentation : $\alpha_{m_k}^{(k)} = \alpha_{m_k}^{(k-1)} + z_{m_k}$.

Algorithme de poursuite adaptative : critères d'arrêt

1. Arrêt après un nombre fini d'itérations.
2. Arrêt lorsque l'amplitude du résiduel est inférieure à un seuil prédéfini.
   - L'inconvénient de cette méthode est que le dictionnaire D n'est pas toujours orthogonale.
   - Dans ce cas, une colonne de la matrice D peut etre sélectionnée à plusieurs reprises pendant la phase de sélection.
   - La MP converge exponentiellement.

La poursuite adaptative

3.2 Orthogonal Maching Pursuit

Le principe de la méthode Orthogonal Matching Pursuit

Décomposer itérativement le signal $x \in \mathbb{R}^N$ dans le dictionnaire $D \in \mathcal{M}_{N \times K}(\mathbb{R})$ par sélection d'un atome à chaque itération :

$$x = \underbrace{\alpha_1^{(n)} d_1 + \alpha_2^{(n)} d_2 + \ldots + \alpha_K^{(n)} d_K}_{\text{Approximation de } x \text{ après } n \text{ itérations}} + \underbrace{R^{(n)}}_{\text{Résiduel après } n \text{ itérations}} .$$

d_j désigne la $j^{\text{ème}}$ colonne de la matrice D.

Algorithmes de reconstruction : Poursuite adaptative orthogonale OMP

1. La phase d'initialisation et de sélection sont les mêmes que pour la poursuite adaptative OM.
2. La méthode de la poursuite adaptative orthogonale OMP améliore la convergence de l'OM : à l'itération k, l'OMP séléctionne le résidu orthogonal avec les colonnes de la matrice D.
3. Une colonne de la matrice D est choisie au maximum une seule fois pendant la phase de séléction.

Les détails de la méthode sont présentés en TD !