Ingénieurs 2ème année : Parcours Mathématique & Informatique

Compressive Sensing

CM 3 : Apprentissage d'un dictionnaire

Nisrine FORTIN

1. Un dictionnaire
2. Construction du dictionnaire
3. L'apprentissage d'un dictionnaire
4. L'apprentissage par la méthode K-SVD

Un dictionnaire

- Un dictionnaire est défini par une matrice $D \in \mathbb{R}^{N \times K}$ où chaque colonne est appelé atome.

- On notera $D = [d_1 \,|d_2\, |\cdots|d_K\,]$, d_i les atomes du dictionnaire.

  - ⇝ Les atomes sont des vecteurs de $\mathbb{R}^{\mathbf{N}}$
  - ⇝ Toute combinaison linéaire de ces atomes mène à un vecteur $x \in \mathbb{R}^{\mathbf{N}}$:

$$\boxed{\alpha_1 \mathbf{d_1} + \alpha_2 \mathbf{d_2} + \cdots + \alpha_K \mathbf{d_K} = x.}$$

$$\alpha_1 \underbrace{\begin{bmatrix} \\ \\ \\ \end{bmatrix}}_{\mathbf{d_1}} + \alpha_2 \underbrace{\begin{bmatrix} \\ \\ \\ \end{bmatrix}}_{\mathbf{d_2}} + \cdots\cdots + \alpha_K \underbrace{\begin{bmatrix} \\ \\ \\ \end{bmatrix}}_{\mathbf{d}_K} = \underbrace{\begin{bmatrix} \\ \\ \\ \end{bmatrix}}_{x}.$$

Un dictionnaire

Sous forme matricielle : $\mathrm{D}\alpha = x$ où le vecteur α est le vecteur de coefficients de la combinaison linéaire :

$$\alpha = \begin{bmatrix} \alpha_1 & \alpha_2 & \cdots & \alpha_K \end{bmatrix}^T .$$

Puisqu'on s'intéresse à la décomposition parcimonieuse, le vecteur α est supposé sparse donc plusieurs coefficients sont nuls et par conséquent, **peu d'atomes seront nécessaires pour représenter x.**

Construction du dictionnaire

Construction du dictionnaire

- Plusieurs techniques sont développées pour construire un dictionnaire D en fonction de l'application à réaliser.
- Le choix du dictionnaire D a une très grande influence sur la qualité de la décomposition α du signal x.
- Si le dictionnaire ne contient pas beaucoup d'atomes adaptés aux structures présentes dans le signal x, la décomposition α sera, quelle que soit la méthode choisie, mauvaise.

Construction du dictionnaire

Le choix du dictionnaire peut être orienté selon plusieurs cirtères :

1. Des connaissances **a priori** permettant de représenter un signal à l'aide des atomes connus dans le domaine de traitement de signal : atomes d'ondelettes et des cosinus locaux,. . ..

   Les connaissances a priori exploitent la répartition et la variation fréquentielle des signaux à analyser à l'aide des atomes harmoniques.

2. **L'apprentissage** à partir des données : on peut exploiter le critère de parcimonie retenu pour un signal ou une image pour construire des dictionnaires adaptés à une famille similaire de signaux et de même nature.

L'apprentissage d'un dictionnaire

L'apprentissage de dictionnaire, appelé aussi encodage parcimonieux, consiste à inférer un dictionnaire à partir d'un ensemble de données de telle sorte qu'il soit adapté à ces données.

- Cet apprentissage doit fournir **conjointement un dictionnaire et une approximation parcimonieuse** pour tous les signaux de cet ensemble.

- Formulation du problème. On dispose d'un ensemble de signaux d'entrainement (ℓ vecteurs connus) qui sont représentatifs de l'ensemble étudié.

- Ces vecteurs d'apprentissage seront représentés dans une matrice X :

$$X = \left[X^{(1)} \,|X^{(2)}\,|\cdots|X^{(\ell)} \right]$$

où $X^{(i)} \in \mathbb{R}^N$.

Objectif

$$\boxed{\text{Apprendre le dictionnaire le plus adapté.}}$$

Les signaux de X ont des approximations parcimonieuses sur ce dictionnaire D

$$\begin{array}{lcll} X^{(1)} & \longrightarrow & \alpha^{(1)}: & X^{(1)} = D\alpha^{(1)} \\ X^{(2)} & \longrightarrow & \alpha^{(2)}: & X^{(2)} = D\alpha^{(2)} \\ \vdots & & & \\ X^{(\ell)} & \longrightarrow & \alpha^{(\ell)}: & X^{(\ell)} = D\alpha^{(\ell)} \end{array}$$

$X = D\Lambda$ où $\Lambda = \left[\alpha^{(1)}|\alpha^{(2)}|\cdots|\alpha^{(\ell)}\right]$. On doit résoudre le problème suivant

$$\min_{D,\Lambda} \|X - D\Lambda\|_F \quad \text{sous les contraintes} \quad \ell_0\left(\alpha^{(i)}\right) \leq s \quad \text{et} \quad \|d_k\|_2 = 1 \qquad (1)$$

$s > 0$ la contrainte de parcimonie de chaque colonne de Λ, $\|.\|_F$ la norme de Frobenius :

$$\|A\|_F = \sqrt{\sum_{i=1}^{N}\sum_{j=1}^{\ell}|a_{ij}|^2}.$$

Apprentissage d'un dictionnaire

Afin de résoudre ce problème, les méthodes d'apprentissage de dictionnaire suivent souvent le même schéma composé de deux étapes majeures :

1. une étape de représentation parcimonieuse,
2. une étape de mise à jour du dictionnaire,

qui sont itérées jusqu'à atteindre un critère d'arrêt.

Apprentissage d'un dictionnaire – L'approche de la méthode K-SVD

L'approche de la méthode K-SVD consiste à résoudre le problème formulé par le problème (1).

- La première étape consiste à résoudre itérativement un problème partiel en $\alpha^{(i)}$ à D fixé (codage parcimonieux).
- La seconde étape consiste à optimiser sur D à $\alpha^{(i)}$ fixé en résolvant

$$\min_{\mathrm{D}} \left(\left\| \mathrm{X} - \mathrm{D}\Lambda \right\|_F^2 \right) \tag{1}$$

Apprentissage d'un dictionnaire – L'approche de la méthode K-SVD

La décomposition en valeurs singulières (Singular Value Decomposition SVD) d'une matrice A consiste à décomposer A sous la forme

$$A = U \Delta V^T.$$

- où U et V sont des matrices unitaires ;
- Δ une matrice dont les éléments diagonaux sont des réels positifs ou nuls, rangés par ordre décroissant appelés valeurs singulières de A.

La décomposition SVD permet d'obtenir la matrice de rang r donnant la meilleure approximation au sens de la norme de Frobenius d'une matrice donnée, sous la forme

$$\widetilde{U} \widetilde{\Delta} \widetilde{V}^T$$

où $\widetilde{\Delta}$ ne compte que les r plus grandes valeurs singulières, $\widetilde{U}$ ne compte que les r premières colonnes de U et $\widetilde{V}$ ne compte que les r premières colonnes de V :

$$A \simeq \underbrace{\widetilde{U} \widetilde{\Delta} \widetilde{V}^T}_{\text{Approximation de rang r de A}}$$

L'algorithme K-SVD

- L'algorithme K-SVD optimise successivement chaque atome du dictionnaire indépendamment des autres atomes supposés fixes.
- À chaque étape, on construit K atomes avec la méthode de la décomposition en valeurs singulières SVD, d'où le nom K-SVD.
- À une étape donnée, on s'intéresse à la $i^{\text{ème}}$ colonne d_i de D et la $i^{\text{ème}}$ ligne de Λ.

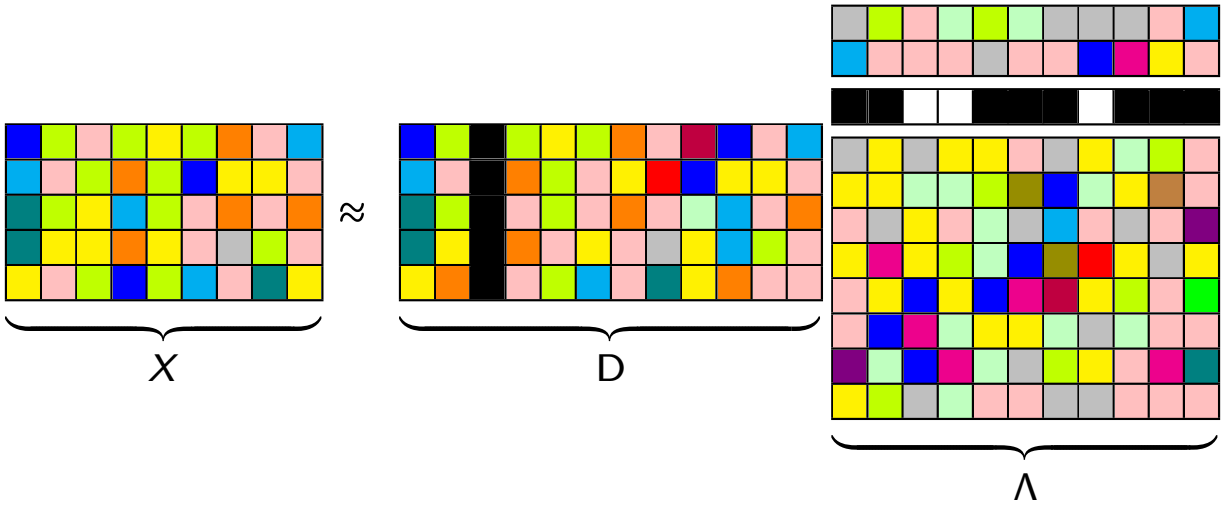

Description de la construction d'un atome d_i, $i \in [\![1, K]\!]$

1. On peut écrire $X = [d_1|d_2|\dots|d_K]\begin{bmatrix} \Lambda_{1,.} \\ \Lambda_{2,.} \\ \vdots \\ \Lambda_{K,.} \end{bmatrix}$ où $\Lambda_{i,.}$ la $i^{\text{ème}}$ ligne de Λ donc

$$X = d_1\Lambda_{1,.} + d_2\Lambda_{2,.} + \dots + d_K\Lambda_{K,.}.$$

2. On note $f(D)$ la fonction objectif du problème d'optimisation (1). On remarque que

$$f(D) = \left\| E_i - d_i\Lambda_{i,.} \right\|_F^2$$

où est E_i est l'erreur sur les ℓ signaux lorsqu'on ne tient plus compte de la contribution de la $i^{\text{ème}}$ colonne de D.

Description de la construction d'un atome d_i, $i \in [\![1, K]\!]$

3. On conserve les coefficients déjà nuls dans la $i^{\text{ème}}$ ligne de Λ, on mettra à jour l'atome d_i en ne tenant compte que des atomes présentant des éléments non nuls au départ. Ceci peut accélerer la convergence de l'algorithme.

4. On note $w_i = \left\{k, \quad 1 \leq k \leq \ell \ \text{ tel que } \Lambda_{i,.}(k) \neq 0\right\}$ le support de la $i^{\text{ème}}$ ligne de Λ.

5. On note $\Lambda^R_{i,.}$ le vecteur ligne obtenu à partir de $\Lambda_{i,.}$ en ne gardant que les coefficients non nuls.

6. On note E^R_i l'erreur de reconstruction sans tenir compte des atomes correspondant aux coefficients nuls de $\Lambda_{i,.}$.

Description de la construction d'un atome d_i, $i \in [\![1, K]\!]$

7. La solution qu'on cherchera va minimiser $\left\| E_i^R - \mathrm{d}_i \Lambda_{i,.}^R \right\|_F^2$ à la fois par rapport à d_i et $\Lambda_{i,.}$.

8. On utilise une décomposition SVD de E_i^R : $E_i^R = U \Delta V^T$.

9. Comme on cherche à minimiser $\left\| E_i^R - \mathrm{d}_i \Lambda_{i,.}^R \right\|_F^2$, on va approcher E_i^R par une matrice de même rang que $\mathrm{d}_i \Lambda_{i,.}^R$.

10. $\mathrm{d}_i \Lambda_{i,.}^R$ est de rang inférieur ou égal à 1 donc on obtient l'approximation

$$E_i^R \simeq \underbrace{\begin{bmatrix} * \\ * \\ \vdots \\ * \end{bmatrix}}_{\widetilde{U}} \underbrace{[*]}_{\widetilde{\Delta}} \underbrace{\begin{bmatrix} * & * & \dots & * \end{bmatrix}}_{\widetilde{V}^T}.$$

11. On retiendra $\mathrm{d}_i = \widetilde{U}$ et $\Lambda_{i,.}^R = \widetilde{\Delta} \widetilde{V}^T$.

Apprentissage d'un dictionnaire

L'algorithme K-SVD a besoin depuis sa première itération d'un dictionnaire D, on pourrait penser à l'initialiser avec des valeurs 0, 1 pour avoir des colonnes de norme égale à 1, mais on va privigier de remplir le dictionnaire initial par les premières colonnes de la matrice des vecteurs d'apprentissage en les normalisant.

Références

1. An Introduction To Compressive Sampling, Emmanuel J. Candès and Michael B. Wakin, EEE SIGNAL PROCESSING MAGAZINE, MARCH 2008.
2. Compressive sampling, Emamnuel J. Candès, Proceedings of the International Congress of Mathematicians, Madrid, Spain, 2006, European Mathematical Society.
3. Thèse : Représentations parcimonieuses pour les signaux multivariés - Quentin Barthélemy
4. Une petite introduction aux représentations parcimonieuses de signaux et d'images -Jérôme Landré 01-07-2008
5. Allen Y. Yang. Compressed sensing meets machine learning - classification of mixture subspace models via sparse representation. Mini Lectures in Image Processing, TRUST Center Seminar, University of California, Berkeley, USA, 2008.
6. Analyse Multi-Résolution et Ondelettes (AMO) Représentations des signaux 1D et 2D, Nicolas Thome Laboratoire d'Informatique de Paris 6 (LIP6) Université Pierre et Marie Curie (UPMC) Master 2 Informatique - Spécialité IMA
7. Compressive sensing Richard G.Baraniuk IEE SIGNAL PROCESSING MAGAZINE [118] JULY 2007
8. R.G. Baraniuk. Compressive sensing [lecture notes]. IEEE Signal Processing Magazine,
9. [DE03] David L. Donoho and Michael Elad. Optimally sparse representation in general (nonorthogonal) dictionaries via l1 minimization. Proceedings of the National Academy of Sciences,
10. Approche d´eterministe de l'acquisition comprimée et la reconstruction des signaux issus de capteurs intelligents distribués THESE présentée et soutenue publiquement le 9 novembre 2015 pour l'obtention du Doctorat de l'Université de Lorraine (mention systèmes électroniques) par Andrianiaina Ravelomanantsoa
11. A User's Guide to Compressed Sensing for Communications Systems Kazunori HAYASHI, Masaaki NAGAHARA, and Toshiyuki TANAHA, IEICE TRANS COMMUN, VOL.E96-B, NO.3 MARCH 2013

Références

12. D.L Donoho, "Compressed sensing", IEEE Tran Inf. Theory, vol52, no.4, pp. 1289-1306 April 2006.
13. E.J. Candes and T.Tao, "Decoding by linear programming" ; IEEE Trans. Inf. Theory, Vol.51, no12, pp.4203-4215, Dec.2005
14. Regression Shrinkage and Selection via the Lasso, Robert Tibshirami, journal of the Royal Statistical Siciety. Series B (Methodological), Volume 58, Issue 1 (1996), 267-288
15. Compressed Sensing with Coherent and Redundant Dictionaries, Emmanuel J. Candes, Yonina C. Eldar, Deanna Needell, Paige Randall, Applied and Computational Harmonic Analysis, Volume 31, Issue 1, July 2011, Pages 59-73
16. Introduction au Compressed Sensing, notions de complexité algorithmique et relaxation convexe, Guillaume Lecué, CNRS, CREST, ENSAE.
17. Cours - Représentation des images et ondelettes, François Malgouyres. Département d'informatique de l'université Paris 13.
18. D.L Donoho, "Compressed sensing", IEEE Tran Inf. Theory, vol52, no.4, pp. 1289-1306 April 2006.
19. E.J. Candes and T.Tao, "Decoding by linear programming" ; IEEE Trans. Inf. Theory, Vol.51, no12, pp.4203-4215, Dec.2005
20. Regression Shrinkage and Selection via the Lasso, Robert Tibshirami, journal of the Royal Statistical Siciety. Series B (Methodological), Volume 58, Issue 1 (1996), 267-288
21. Compressed Sensing with Coherent and Redundant Dictionaries, Emmanuel J. Candes, Yonina C. Eldar, Deanna Needell, Paige Randall, Applied and Computational Harmonic Analysis, Volume 31, Issue 1, July 2011, Pages 59-73
22. Introduction au Compressed Sensing, notions de complexité algorithmique et relaxation convexe, Guillaume Lecué, CNRS, CREST, ENSAE.
23. Représentations parcimonieuses et apprentissage de dictionnaires pour la compression et la classification d'images satellites, Jérémy Aghaei Mazaheri, Thèse université de Rennes 1, 2015.
24. La technique du Matching Pusuit, Présentation de M2RI-Module ARD, Université de Rennes 1 - INSA de Rennes.