Ingénieurs 2ème année : Parcours Mathématique & Informatique

Compressive Sensing

CM 4 : Réduction de dimension et matrice de mesure

Nisrine FORTIN

1. La réduction de dimension
   - Sélection de caractéristiques
   - Extraction de caractéristiques
2. La phase d'acquisition
   - Matrice de mesure
   - Restricted Isometry Property
   - Cohérence
   - Cohérence mutuelle
3. Exemples de matrices de mesure

La réduction de dimension

La réduction de dimension

On considère ℓ vecteurs définis dans l'espace $\mathbb{R}^N$, $X^{(j)} \in \mathbb{R}^d$, $j = 1, \ldots, \ell$. On note dans la suite, pour $j \in [\![1; \ell]\!]$,

$$X^{(j)} = \left[X_1^{(j)}\ X_2^{(j)} \ldots\ X_N^{(j)}\right].$$

- Lorsque la dimension N des données est grande, la complexité des calculs et la capacité en mémoire peuvent s'avérer problématiques.
- Cependant, plus un modèle est simple, moins il y a de variance et plus on diminue les coûts de mesures.
- Il est souvent plus facile d'expliquer un modèle avec moins de composantes et en extraire des connaissances, et l'analyse de résultats est souvent plus aisée en **visualisant** moins de données.

La réduction de dimension

- La réduction de la dimensionnalité devient alors un outil très important afin de trouver une nouvelle représentation avec peu d'attribus,
- elle consiste à passer d'un espace de dimension N vers un espace de dimension M où $M \ll N$:

$$\underbrace{\left[X_1^{(j)}\ X_2^{(j)} \dots X_N^{(j)}\right]^t}_{X^{(j)}} \xrightarrow{\text{Réduire la dimension}} \underbrace{\left[Y_1^{(j)}\ Y_2^{(j)} \dots Y_M^{(j)}\right]^t}_{Y^{(j)}}.$$

La réduction de dimension

Pour ce faire, deux approches sont possibles :

1. La sélection de caractéristiques : on choisit M attribus parmi les N attribus possibles.

2. L'extraction de caractéristiques : on génére M attribus comme des transformations des N attribus d'origine.

La réduction de dimension

Sélection de caractéristiques

Sélection de caractéristiques

La sélection des caractéristiques a pour but de trouver un sous-ensemble de M attribus parmi N attribus tout en préservant **les performances** du modèle.

- La sélection consiste à trouver un sous-ensemble d'attributs qu'on trie par ordre d'importance.
- Le nombre de sous-ensembles possibles est de l'ordre de C_N^M, donc on cherche un algorithme qui fournit rapidement une solution réalisable et pas nécessairement optimale.

$$\underbrace{\begin{pmatrix} X_1^{(j)} \\ X_2^{(j)} \\ \vdots \\ \vdots \\ X_N^{(j)} \end{pmatrix}}_{X^{(j)}} \begin{matrix} \longrightarrow \\ \longrightarrow \\ \longrightarrow \\ \\ \longrightarrow \end{matrix} \left.\underbrace{\begin{pmatrix} X_{i_1}^{(j)} \\ X_{i_2}^{(j)} \\ \vdots \\ X_{i_M}^{(j)} \end{pmatrix}}_{Y^{(j)}}\right\} \text{Sélection de M attribus parmi N attribus}$$

Sélection de caractéristiques

Plusieurs approches sont proposées :

- Séléctionner les attribus selon des mesures de performances individuelles.
- Sélectionner les attribus selon les informations mutuelles entre les caractéristiques.
- Sélectionner les attribus en organisant les caractéristiques en arbre selon leur similarité puis on réduit par coupe dans l'arbre afin d'éliminer les caractéristiques similaires. Il s'agit du principe du Branch and Bound.

Sélection de caractéristiques - Remarques

- L'ensemble de ces approches est fondé sur des heuristiques et utilise des hypothèses d'apprentissage.
- On doit considérer un critère de sélection et un critère d'arrêt approprié.
- Un point faible de ces approches est l'élimination parfois de plusieurs attribus pauvres en informations lorsqu'elles sont considérées individuellement mais riches en informations lorsqu'elles sont prises collectivement.

La réduction de dimension

Extraction de caractéristiques

Extraction de caractéristiques

- On projète un espace de diemnsion N dans un espace de dimension M en utilisant une transformation qui permettrait de **préserver les informations** principales de l'espace de départ.

- On projette tout élément $x \in \mathbb{R}^N$ sur $\mathbb{R}^M$ où $M \ll N$ selon le critère de minimisation de la distorsion ou la perte d'informations.

$$\begin{cases} Y_1^{(j)} & = & f_1\left(\left[X_1^{(j)}\ X_2^{(j)} \dots X_N^{(j)}\right]^t\right) \\ Y_2^{(j)} & = & f_2\left(\left[X_1^{(j)}\ X_2^{(j)} \dots X_N^{(j)}\right]^t\right) \\ \vdots & & \\ \vdots & & \\ Y_M^{(j)} & = & f_M\left(\left[X_1^{(j)}\ X_2^{(j)} \dots X_N^{(j)}\right]^t\right) \end{cases}$$

Extraction de caractéristiques

Plusieurs approches sont proposées :

- **L'analyse en composantes principales :**
  - on cherche un nouvel ensemble d'attributs déterminés à partir d'une projection linéaire dans un espace à K dimension.
  - Ils sont obtenus à partir d'une combinaison linéaire des attribus d'origine et l'individu moyen en minimisant la perte d'information.

- **La projection aléatoire :**
  - on construit une matrice $A^{'} \in \mathbb{R}^{\mathsf{M}\times\mathsf{N}}$ en prenant en entrée comme des valeurs d'une variable aléatoire suivant une loi normale,
  - on orthonormalise les lignes de $A^{'}$ et on obtient une matrice A.
  - La projection de chaque vecteur $\mathsf{X}^{(j)} \in \mathbb{R}^{\mathsf{N}}$ est donnée par $A\mathsf{X}^{(j)}$.

- **Le compressive sensing** :
  - les données de grandes dimensions (images, signaux audio, etc.) sont souvent **parcimonieuses**.
  - L'idée principale est au lieu de s'intéresser au vecteur x, on travaillera avec sa représentation parcimonieuse et on ne collectera que M données de façon aléatoire.

La phase d'acquisition

État des lieux de ce qui ce fait – Acquisition puis Compression

On fait l'acquisition des N composantes, on transforme chaque vecteur en représentation parcimonieuse, on ne garde que les coefficients non nuls et leur position.

Mais puisqu'on ne garde qu'une partie des composantes déjà acquises, **pourquoi ne pas acquérir uniquement que ce dont on a besoin ?** C'est de cette question que part l'idée du Compressive Sensing : proposer une méthode d'acquisition et compression **simultanée** qui ne conserve que le nécessaire de l'information pour être être capable de reconstruire le signal.

On souhaite acquérir directement des mesures sur le vecteur $X^{(j)}$ en s'assurant que le vecteur $Y^{(j)}$ nous permette de reconstruire le vecteur d'origine $X^{(j)}$. Pour simplifier les notations, on travaille avec un vecteur d'origine noté $x \in \mathbb{R}^N$.

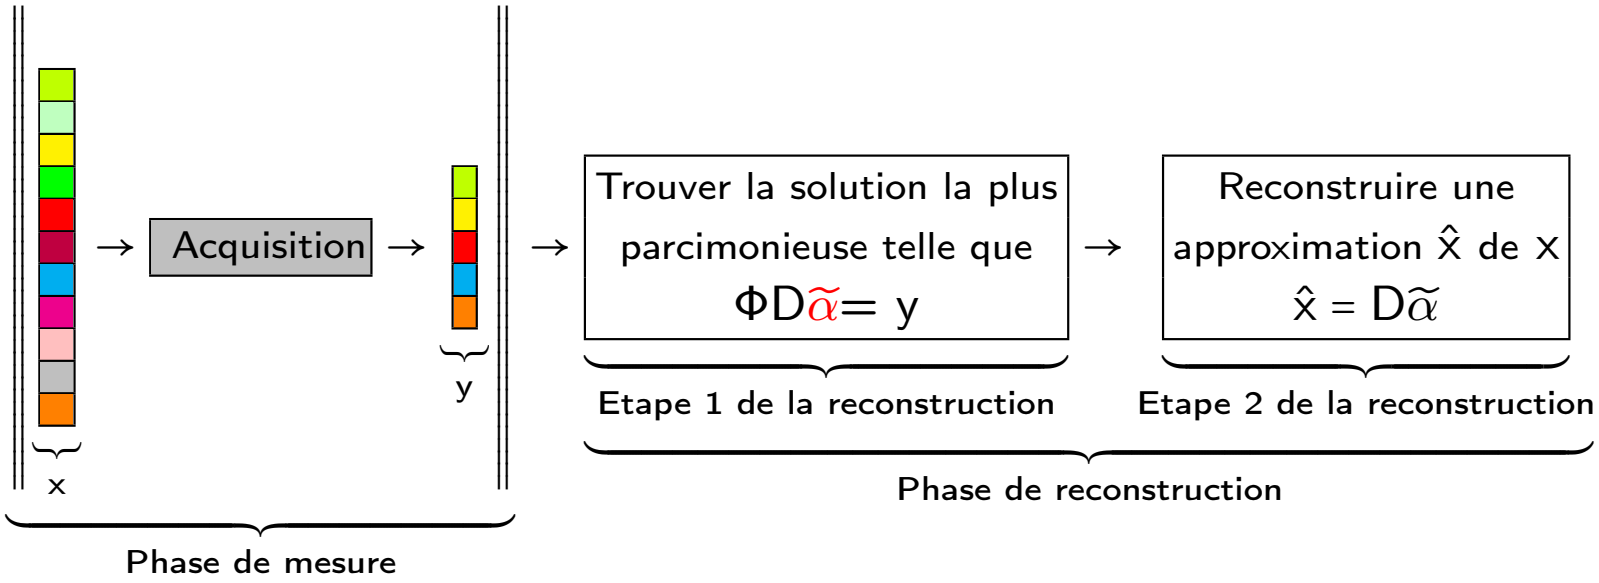

Le processus de mesure (acquisition) peut être représenté par la matrice Φ d'ordre $M \times N$ tel que $y = \Phi x$.

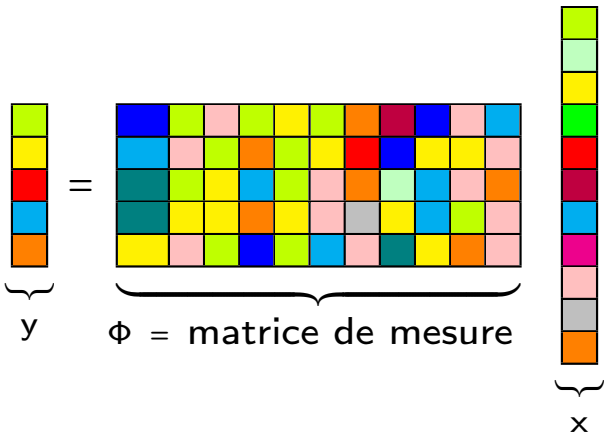

- La matrice Φ est appelée la matrice de mesure et elle doit être conçue pour que la phase d'acquisition n'altère pas l'information contenue dans le signal original.

- La matrice de mesure intervient dans la phase d'acquisition mais elle doit être conçue pour **assurer la reconstruction du signal parcimonieux**.

Discussion et questions clés

- Pendant **la phase de mesure**, quelles sont les critères que la matrice de mesure Φ devrait satisfaire ? Comment définir une "bonne" mesure permettant de comprimer le signal d'origine mais en préservant la structure s-sparse du signal ?
- Pendant **la phase de reconstruction**, comment reconstruire efficacement (sans perte ou avec perte contrôlée) le signal original à partir de y, Φ et D ?
- Quel est **le nombre minimal de mesures** M nécessaires pour reconstruire correctement le signal original ?

Nombre minimal de mesures

- La matrice de mesure intervient dans un système hautement sous-déterminé, N étant la taille du signal (fixée), l'utilisateur intervient dans la phase d'acquisition avec un nombre de mesures M qui intervient directement dans la recherche de la solution s-sparse.

- Si on veut avoir une chance de retrouver α à partir de $A\alpha$, on doit considérer un nombre minimal de mesures nécessaire et orienter le $\ker(A)$.

Proposition 1

Les assertions suivantes sont équivalentes :

1. $\forall \alpha \in \Sigma_s,\ \forall \beta \in \Sigma_s,\ \alpha \neq \beta \Rightarrow A\alpha \neq A\beta$.

2. $\ker(A) \cap \Sigma_{2s} = \{0\}$ (donc $M \geq 2s$).

Une conclusion nous permettra d'émettre une hypothèse pour la reconstruction exacte à partir du problème de minimisation (ℓ_0) de la solution s-sparse avec un nombre minimal de mesures.

Proposition 3

Les assertions suivantes sont équivalentes :

1. $\ker(A) \cap \Sigma_{2s} = \{0\}$.
2. La procédure de minimisation ℓ_0 permet de reconstruire exactement tout vecteur de Σ_s.

$2s$ est le nombre nécessaire et suffisant pour pouvoir reconstruire exactement tout vecteur s-sparse. La procédure de minimisation (ℓ_0) fournit dans ce cas une procédure de reconstruction exacte quand la matrice de mesure A vérifie la condition

$$\ker(A) \cap \Sigma_{2s} = \{0\}\,.$$

Restricted Isometry Property

- Une matrice A satisfait le restricted isometry property RIP d'ordre s s'il existe une constante $0 < \delta_s < 1$ telle que

$$\forall \alpha \in \Sigma_s, \quad (1-\delta_s)\|\alpha\|_2^2 \leq \|A\alpha\|_2^2 \leq (1+\delta_s)\|\alpha\|_2^2$$

- La plus petite constante vérifiant le RIP d'ordre s est appelée Restricted Isometry Constant (RIC). Cette constante peut être interprétée comme une mesure du degré d'orthogonalité du dictionnaire pour des sous-espaces de différentes dimensions.

- Le RIP permet de vérifier si la matrice de mesure A est proche d'une isomérie, c'est-a-dire si elle préserve la distance entre deux vecteurs de mesure.

- Si la matrice de mesure satisfait le RIP d'ordre $2s$, alors la distance entre deux vecteurs de mesure $y_1 = A\alpha_1$ et $y_2 = A\alpha_2$ est proportionnelle à la distance entre α_1 et α_2.
- Le RIP est une propriété importante qui permet de garantir la reconstruction du signal.

Cohérence

La cohérence $\mu(\mathrm{A})$ d'une matrice A est égale à la plus grande valeur absolue du produit scalaire entre deux vecteurs colonnes distincts de A :

$$\mu(\mathrm{A}) = \max_{i \neq j} \frac{\left|\langle a_i, a_j \rangle\right|}{\|a_i\|_2 \|a_j\|_2}$$

où a_i et a_j sont les colonnes de la matrice A. La cohérence permet de mesurer la corrélation maximale entre les différents vecteurs colonnes d'une matrice.

- Lorsque $\mathrm{M} \ll \mathrm{N}$, $\frac{1}{\sqrt{\mathrm{M}}} \leq \mu(\mathrm{A}) \leq 1$.
- Une matrice A est dite **incohérente** lorsque la valeur de $\mu(\mathrm{A})$ tend vers la limite de *Welch* $\frac{1}{\sqrt{\mathrm{M}}}$.

Unicité et la cohérence

Si la relation suivante est satisfaite

$$s < \frac{1}{2}\left(1 + \frac{1}{\mu(\mathrm{A})}\right)$$

alors pour tout vecteur de mesure $y \in \mathbb{R}^M$, il existe au plus un signal $\alpha \in \mathbb{R}^N$ tel que $y = A\alpha$

La matrice de mesure A doit avoir une faible cohérence :

- une faible valeur de la cohérence μ augmente la borne supérieure de s.
- Pour minimiser la valeur de μ, il faut que les vecteurs colonnes de A soient les plus orthogonaux possibles.

Cohérence mutuelle

- La notion de cohérence peut être étendue pour une paire de matrices. La cohérence mutuelle entre Φ et D est définie comme suit

$$\mu\big(\Phi, \mathrm{D}\big) = \sqrt{N} \max_{i \neq j} \frac{\left|\left\langle \Phi_i, \mathrm{D}_j \right\rangle\right|}{\|\Phi_i\|_2 \|\mathrm{D}_j\|_2}$$

où Φ_i et D_j représentent respectivement les vecteurs lignes de Φ et les vecteurs colonnes de D.

- La cohérence mutuelle mesure la corrélation maximale entre les vecteurs lignes de Φ et les vecteurs colonnes de D. La plage de valeurs de la cohérence mutuelle est

$$1 \leq \mu\big(\Phi, \mathrm{D}\big) \leq \sqrt{\mathrm{N}}.$$

Exemples de matrices de mesure

- Lorsque les matrices de mesure sont construites aléatoirement, les conditions vues précédemment peuvent être remplies avec une forte probabilité.

- En particulier, lorsque les éléments de la matrice de mesure A de type $M \times N$ sont générés à partir :

  1. d'un processus gaussien identique et Indépendamment distribué (i.i.d) avec une moyenne nulle et une variance $\frac{1}{M}$: $N\left(0, \frac{1}{M}\right)$;
  2. d'un processus aléatoire équiprobable prenant des valeurs $\pm\frac{1}{\sqrt{M}}$.

Exemples de matrices de mesure

- Φ_1 : matrice aléatoire générée à partir d'un processus uniformément distribué.
- Φ_2 : matrice aléatoire générée à partir d'un processus bernoullien $\{-1, 1\}$. (Si rand()<p alors X=-1 sinon X=1).
- Φ_3 : matrice aléatoire générée à partir d'un processus bernoullien $\{0, 1\}$.
- Φ_4 : matrice aléatoire générée à partir d'un processus gaussien identique et indépendamment distribué (i.i.d) avec une moyenne nulle et une variance $\frac{1}{M}$: $N\left(0, \frac{1}{M}\right)$;
- Φ_5 : matrice creuse ou parcimonieuse générée de façon aléatoire.

Références

1. An Introduction To Compressive Sampling, Emmanuel J. Candès and Michael B. Wakin, EEE SIGNAL PROCESSING MAGAZINE, MARCH 2008.
2. Compressive sampling, Emamnuel J. Candès, Proceedings of the International Congress of Mathematicians, Madrid, Spain, 2006, European Mathematical Society.
3. Thèse : Représentations parcimonieuses pour les signaux multivariés - Quentin Barthélemy
4. Une petite introduction aux représentations parcimonieuses de signaux et d'images -Jérôme Landré 01-07-2008
5. Allen Y. Yang. Compressed sensing meets machine learning - classification of mixture subspace models via sparse representation. Mini Lectures in Image Processing, TRUST Center Seminar, University of California, Berkeley, USA, 2008.
6. Analyse Multi-Résolution et Ondelettes (AMO) Représentations des signaux 1D et 2D, Nicolas Thome Laboratoire d'Informatique de Paris 6 (LIP6) Université Pierre et Marie Curie (UPMC) Master 2 Informatique - Spécialité IMA
7. Compressive sensing Richard G.Baraniuk IEE SIGNAL PROCESSING MAGAZINE [118] JULY 2007
8. R.G. Baraniuk. Compressive sensing [lecture notes]. IEEE Signal Processing Magazine,
9. [DE03] David L. Donoho and Michael Elad. Optimally sparse representation in general (nonorthogonal) dictionaries via l1 minimization. Proceedings of the National Academy of Sciences,
10. Approche d´eterministe de l'acquisition comprimée et la reconstruction des signaux issus de capteurs intelligents distribués THESE présentée et soutenue publiquement le 9 novembre 2015 pour l'obtention du Doctorat de l'Université de Lorraine (mention systèmes électroniques) par Andrianiaina Ravelomanantsoa
11. A User's Guide to Compressed Sensing for Communications Systems Kazunori HAYASHI, Masaaki NAGAHARA, and Toshiyuki TANAHA, IEICE TRANS COMMUN, VOL.E96-B, NO.3 MARCH 2013

Références

12. D.L Donoho, "Compressed sensing", IEEE Tran Inf. Theory, vol52, no.4, pp. 1289-1306 April 2006.
13. E.J. Candes and T.Tao, "Decoding by linear programming" ; IEEE Trans. Inf. Theory, Vol.51, no12, pp.4203-4215, Dec.2005
14. Regression Shrinkage and Selection via the Lasso, Robert Tibshirami, journal of the Royal Statistical Siciety. Series B (Methodological), Volume 58, Issue 1 (1996), 267-288
15. Compressed Sensing with Coherent and Redundant Dictionaries, Emmanuel J. Candes, Yonina C. Eldar, Deanna Needell, Paige Randall, Applied and Computational Harmonic Analysis, Volume 31, Issue 1, July 2011, Pages 59-73
16. Introduction au Compressed Sensing, notions de complexité algorithmique et relaxation convexe, Guillaume Lecué, CNRS, CREST, ENSAE.
17. Cours - Représentation des images et ondelettes, François Malgouyres. Département d'informatique de l'université Paris 13.
18. D.L Donoho, "Compressed sensing", IEEE Tran Inf. Theory, vol52, no.4, pp. 1289-1306 April 2006.
19. E.J. Candes and T.Tao, "Decoding by linear programming" ; IEEE Trans. Inf. Theory, Vol.51, no12, pp.4203-4215, Dec.2005
20. Regression Shrinkage and Selection via the Lasso, Robert Tibshirami, journal of the Royal Statistical Siciety. Series B (Methodological), Volume 58, Issue 1 (1996), 267-288
21. Compressed Sensing with Coherent and Redundant Dictionaries, Emmanuel J. Candes, Yonina C. Eldar, Deanna Needell, Paige Randall, Applied and Computational Harmonic Analysis, Volume 31, Issue 1, July 2011, Pages 59-73
22. Introduction au Compressed Sensing, notions de complexité algorithmique et relaxation convexe, Guillaume Lecué, CNRS, CREST, ENSAE.
23. Représentations parcimonieuses et apprentissage de dictionnaires pour la compression et la classification d'images satellites, Jérémy Aghaei Mazaheri, Thèse université de Rennes 1, 2015.
24. La technique du Matching Pusuit, Présentation de M2RI-Module ARD, Université de Rennes 1 - INSA de Rennes.